

Proyecto Final

Bootcamp Data Analytics

NEOLAND 2025

Jacinto Arjona Garrido, Giada Ceresa, Carla López, Natalia Martinez

Proyecto Data Analytics




Etapas de Crecimiento



¿Qué Analizamos?



Alcance y Objetivos



Limpieza de datos y Tendencias



Modelo de Machine Learning



Conclusion y Proximos Pasos

Crecimiento del proyecto a nivel global

Etapa 01

BÚSQUEDA

Búsqueda de bases de datos en Kaggle.
Cumplir requerimientos, verificar información, Cambio de objetivo, adaptación.

Etapa 02

LIMPIEZA

Uso de Python
Primera limpieza para la preparación de los datos, graficos exploratorios, union de diversas tablas.

Etapa 03

MODELOS

Uso de Python
Preparación de datos para la puesta en práctica de Modelos de Machine Learning para lograr resultados óptimos.

Etapa 04

CONCLUSIONES

Uso de Power BI.
Interpretación de los resultados obtenidos, generación de nuevas propuestas y posibles pasos a seguir.

Búsqueda de los Datos

Logistics Supply chain 2 tablas y 44 columnas	Steam Games Dataset 2 tablas y 186 columnas	E-Commerce & Retail Supply Chain 5 tablas y 74 columnas	Smart Devices from 99's to Today 1 tabla y 272 columnas	SEO Performance Data 1 tabla y 44 columnas
---	---	---	---	--

Brazilian E-Commerce Public Dataset by Olist & Marketing Funnel
9 tablas y 52 columnas & 2 tablas con 18 columnas
casi 100.000 filas de datos

Comenzamos la búsqueda con la visión general sobre
“La predicción del éxito para el lanzamiento de un nuevo producto”
que conforme hacíamos la revisión de los diferentes datasets,
decidimos cambiar el objetivo del proyecto a:

“LA PREDICCIÓN DE LA SATISFACCIÓN DEL CLIENTE”

¿Qué Analizamos?

OLIST, se trata un E-Commerce con una base de datos públicos que contiene información de pedidos realizados entre 2016 y 2018.

Los datos permiten visualizar todas las instancias de cada pedido hasta las **reseñas de los clientes**.



ALCANCE

- Predicción binaria:
 - Muy Buena** Reseña
 - No** muy Buena Reseña
- Enfoque en riesgo crítico, pero **no** en la puntuación
- Modelo aplicable a otras plataformas de E-Commerce



OBJETIVO

- Algoritmo de Machine Learning,
 - capaz de clasificar las probabilidades de satisfacción de los clientes.
- Sistema de Alerta Temprana:
 - Detectar posibles reseñas negativas incluso antes que sucedan y evitarlas.

Tablas y Datos




Análisis preliminar tablas:


- Valores faltantes en tablas
- Valores sin emparejamientos entre tablas.
- Datos innecesarios para nuestro scope.
- Generación de tabla general.
- Limpieza para aplicación a diferentes modelos.

Multiples modelos


- Al generar un data para varios modelos, es necesario realizar una limpieza posterior para cada modelo.



Decisiones de negocio y transformaciones




01 Paso de variables **categoricas** a **booleanos**




- **Estado del pedido**

Entregado
[8 valores
originales]




- **Review**

1,2,3,4 -> 5
[5 valores
originales]



- **Tipo de pago**

Credit Card
[5 valores
originales]



- **Localizacion geografica**

Region
[24 valores
originales]

02 Descartes de columnas

- Columnas fuera de scope, product_name_length, Fechas, customer_zip_code_prefix, ect...
- Columnas usadas para cálculo de otras, como el caso de review o retraso en la entrega.

03 Unificacion de tablas

- Muchos NaNs por valores faltantes dentro de cada tabla.
- Faltan valores en todas las tablas al unificar.
- Usamos como base Review
- Usamos las tablas agrupadas por order_id.

Reviews: agrupado por orders

- **Review Score:** Media de los orders
- **Review creation** date: La mas reciente.

Payments: agrupado por orders.

- **Number Payments:** size
- **Payment Value Sum:** suma
- **Number Payments Type:** cantidad de pagos diferentes
- **Payment type:** el tipo de pago, “**Multiple**” en caso de haber mas de uno.

Items: agrupado por orders.


- **Total Price:** sum
- **Freight Value:** sum
- **Number Payments Type:** unique
- **Payment type:** “**multiple**” en caso de haber mas de uno
- **Product Description Length:** Max
- **Product Photos Qty :** Max
- **Product Weight G:** Max
- **Product Length Cm:** Max
- **Product Height Cm:** Max
- **Product Width Cm:** Max
- **Seller ID:** “multiple”, si mas de uno
- **Product ID:** “multiple”, si mas de uno
- **Category:** el de precio mayor dentro del pedido.

04 Relleno y descarte de filas

- **Moda de la tabla base:**
 - "product_description_lenght", "product_photos_qty", "product_weight_g", "product_length_cm", "product_height_cm", "product_width_cm"
- **Unknown:**
 - "product_category_name_english", "seller_state", "product_id," "seller_id"
- **Tiempo de retraso:**
 - Establecemos un valor de retraso en el caso de que no se haya entregado.

05 Tabla final reduccion Categorías

- Reducimos las **categorías**, de 74 a 6 opciones.
 - 'Miscellaneous and Other Items', 'Home and Decoration', 'Fashion and Personal Care', 'Tools and Construction', 'Electronics and Technology' y 'Leisure, Toys and Arts'





Selección de modelos predictivos


VARIABLE A PREDECIR:

satisfacción del cliente

- Dato ya conocido
- Categorical [binaria o multiclase]

OBJETIVO DEL MODELO:

- predecir y explicar



MODELOS DISPONIBLES:

1. Regresión logística
2. Árboles de decisión
3. KNN
4. Random Forest
5. Gradient Boosting



Comparación de resultados y selección de modelo

Indicador	Regresión Logística	Arboles de Decisión	Random Forest	K-Nearest Neighbors	Gradient Boosting [binario]	Gradient Boosting [multiple]
ROC-AUC score Calidad del ranking						
f1_score Balance de seguridad						
accuracy Acierto general						
sensibility (o recall) Tasa de Verdaderos Positivos						
specificity Tasa de Verdaderos Negativos						



Desarrollo del modelo

01.

Limpieza de
Datos y
Ajuste de
Columnas

02.

Reducción de
Correlación
Cruzada

03.

Repartición
Train/Test y
Normalización

04.

Selección de
variables
relevantes

05.

Ajuste de
asimetría de
datos



01. Ajuste de Columnas

Variable Target:
review_score

Reducción a
binaria

Variable
delay_time

Reducción a
binaria

Variables
Categoricas

*según distribución
de frecuencia*


Reducción a
1 categoría
Transformación
en dicotómicas


Variables que
podían generar
ruido

Eliminación




02. Correlación Cruzada





03. Repartición datos de training y de testing





04. Selección de variables relevantes

RESULTADO
TRANSFORMACIONES
Y SELECCIÓN:

23 columnas



RFE con varios
números de
columnas,
evaluando eficacia
del modelo según
`roc_auc_score`




RESULTADO de la
SELECCIÓN:

14 columnas



05. Ajuste de asimetría de datos




Ajuste en
código



Selección
de umbral
0.54




Resultados, resumen métricas:





Resultados, variables de peso:

feature	peso_abs
delayed_order	2.129925
delivered_status	0.750170
product_category_name_english_Leisure, Toys an...	0.275445
product_category_name_english_Fashion and Pers...	0.256695
number_items	0.223253
product_category_name_english_Miscellaneous an...	0.223067
product_category_name_english_Tools and Constr...	0.203186
customer_southeast_state	0.107623
seller_southeast_state	0.062341
product_category_name_english_Home and Decoration	0.059479
number_payments	0.023735
credit_card_payment_1	0.008754
product_height_cm	0.001379
product_length_cm	0.001325




Influencia del retraso

olist

Pedidos retrasados

8 mil


Media Review Score




Promedio Review por Dias de retraso




Puntuaciones en Pedidos retrasados






Influencia de las categorías





Influencia del estado de la entrega





Implicaciones para el negocio

- El modelo es más adecuado como herramienta de análisis que como predictor operativo en su estado actual.
- Permite identificar riesgos y ambigüedades clave antes de activar acciones de marketing
- Su rendimiento refleja la subjetividad y el ruido humano presentes en las valoraciones de los clientes.



Próximos Pasos

01

Foco en el
contenido de las
Reviews

02

Mejora de
Outliers

03

Estudio de
variables sobre el
tiempo de retraso

Gracias,
¿Alguna pregunta?

